

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

**«БЕЛГОРОДСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНОЛОГИЧЕСКИЙ
УНИВЕРСИТЕТ им. В. Г. Шухова»
(БГТУ им. В. Г. Шухова)**



Кафедра программного обеспечения вычислительной
техники и автоматизированных систем

Лабораторная работа №4
по дисциплине: «Параллельное программирование»
на тему: «Параллельное программирование с использованием OpenCL»

Выполнил: ст. группы ПВ-223
Дмитриев Андрей Александрович

Проверили:
доц. Островский Алексей Мичеславович,

Белгород, 2025

Цель работы: Изучить основы параллельного программирования с использованием OpenCL, реализовать вычислительные задачи с применением графического ускорителя (GPU), оценить производительность и масштабируемость решений при выполнении вычислений.

Цель работы обуславливает постановку и решение следующих **задач**:

1. Изучить архитектуру и программную модель OpenCL, включая понятия платформ, устройств, контекстов, очередей команд, ядер (kernels), рабочих элементов и групп.
2. Освоить процесс компиляции и запуска OpenCL-программ в среде Linux, включая настройку окружения, установку драйверов и инструментов, проверку доступности устройств и базовую сборку кода.
3. Реализовать задачу-пример с использованием OpenCL, реализующую умножение двух квадратных матриц большого размера.
4. Научиться загружать и исполнять OpenCL-ядра, передавать данные между CPU (хост) и GPU (устройство), управлять памятью, синхронизацией и чтением результатов.
5. Изучить подходы к декомпозиции вычислительной задачи для GPU, включая:
 - 5.1 Разбиение задачи на элементарные операции (work-items),
 - 5.2 Разбиение массива или данных на блоки (work-groups).
 - 5.3 Определение схемы обращения к данным (coalesced memory access).
 - 5.4 Минимизацию конфликтов доступа и использование локальной памяти устройства.
6. Выполнить индивидуальное задание, связанное с реализацией вычислительной задачи на OpenCL: декомпонировать задачу на параллельно исполняемые фрагменты (work-items и work-groups), обеспечить эффективное распределение вычислений между элементами устройства, обратить внимание на балансировку нагрузки, схему

обращения к памяти и взаимодействие между уровнями иерархии памяти (глобальная, локальная, приватная).

7. Провести сравнение производительности OpenCL-программ с однопоточными реализациями на CPU, выявить выигрыш в скорости, определить факторы, влияющие на масштабируемость (размер входных данных, конфигурация устройства, количество work items).

8. Оформить отчёт с выводами по эффективности параллельного подхода, включая:

8.1 Описание архитектурных решений.

8.2 Анализ времени выполнения.

8.3 Графики ускорения и зависимостей.

8.4 Оценку применимости OpenCL к подобным задачам в практической деятельности.

Условие индивидуального задания:

2. Реализовать параллельные алгоритмы для обучения и предсказания с помощью модели нейронной сети с одним скрытым слоем. Параллелизовать вычисления прямого и обратного прохода нейронной сети для каждого обучающего примера, обеспечить эффективную работу на GPU, сравнить производительность с CPU. Дан набор данных `dataset[N][D]` (загрузить из файла), где `N` — количество обучающих примеров, `D` — размерность признакового пространства. Дан вектор меток `labels[N]`, содержащий выходные значения (0 или 1). Нейронная сеть включает: один скрытый нейрон с функцией активации `sigmoid`; один выходной нейрон с функцией активации `sigmoid`. Требуется реализовать параллельный прямой проход (`forward pass`) через сеть, когда каждая параллельная нить (`thread`) вычисляет выход сети для одного обучающего примера. Реализовать параллельное обратное распространение ошибки (`backpropagation`), когда каждая нить вычисляет локальные градиенты по одному примеру; затем реализовать редукцию (суммирование) градиентов для обновления весов. Обеспечить эффективную работу алгоритма на GPU с использованием OpenCL. После обучения вывести предсказания на обучающем наборе данных и на новом тестовом примере. Сравнить производительность (по времени выполнения) между реализациями на GPU и CPU. Для данных использовать базовый тип `float`. (См. однопоточный прототип в файле `2.py`)

Ход выполнения работы

В реализации присутствуют большие блоки математических вычислений они выведены на GPU, а именно прямой и обратный проход с пересчётом весов.

Текст программы на языке Rust.

main.rs

```
use ocl::flags::MEM_READ_WRITE;
use ocl::{Buffer, Device, Kernel, Platform, Program, Queue};
use rand::Rng;

const INPUT_SIZE: usize = 5;
const LEARNING_RATE: f32 = 0.1;
const EPOCHS: usize = 100_000;

struct NeuralNetwork {
    w_input_hidden: Vec<f32>,
    w_hidden_output: f32,
    bias_hidden: f32,
    bias_output: f32,
    queue: Queue,
    forward_kernel: Kernel,
    backward_kernel: Kernel,
}

impl NeuralNetwork {
    fn new() -> Self {
        let mut rng = rand::thread_rng();

        // Initialize weights
        let w_input_hidden: Vec<f32> = (0..INPUT_SIZE).map(|_| rng.gen_range(-1.0..1.0)).collect();
        let w_hidden_output = rng.gen_range(-1.0..1.0);
        let bias_hidden = rng.gen_range(-1.0..1.0);
        let bias_output = rng.gen_range(-1.0..1.0);

        // Initialize OpenCL
        let platform = Platform::first().expect("No OpenCL platform found");
        let device = Device::first(platform).expect("No OpenCL device found");
        let context = ocl::Context::builder()
            .platform(platform)
            .devices(device)
            .build()
            .expect("Failed to create OpenCL context");
        let queue = Queue::new(&context, device, None).expect("Failed to create OpenCL queue");

        // Compile OpenCL program
        let program = Program::builder()
            .src(include_str!("kernels.cl"))
```

```

        .devices(device)
        .build(&context)
        .expect("Failed to build OpenCL program");

    // Create kernels
    let forward_kernel = Kernel::builder()
        .program(&program)
        .name("forward_pass")
        .queue(queue.clone())
        .global_work_size(1) // One work item per sample
        .arg(None:::<&Buffer<f32>>) // input
        .arg(None:::<&Buffer<f32>>) // weights
        .arg(None:::<&Buffer<f32>>) // hidden_input
        .arg(0.0f32) // bias_hidden
        .build()
        .expect("Failed to create forward kernel");

    let backward_kernel = Kernel::builder()
        .program(&program)
        .name("backward_pass")
        .queue(queue.clone())
        .global_work_size(1) // One work item per sample
        .arg(None:::<&Buffer<f32>>) // input
        .arg(None:::<&Buffer<f32>>) // weights
        .arg(0.0f32) // d_hidden_output
        .arg(0.0f32) // learning_rate
        .build()
        .expect("Failed to create backward kernel");

    NeuralNetwork {
        w_input_hidden,
        w_hidden_output,
        bias_hidden,
        bias_output,
        queue,
        forward_kernel,
        backward_kernel,
    }
}

fn sigmoid(&self, x: f32) -> f32 {
    1.0 / (1.0 + (-x).exp())
}

fn sigmoid_derivative(&self, x: f32) -> f32 {
    let s = self.sigmoid(x);
    s * (1.0 - s)
}

fn forward_pass(&self, x: &[f32]) -> (f32, f32, f32, f32) {
    // Create buffers

```

```

let x_buffer = Buffer::<f32>::builder()
    .queue(self.queue.clone())
    .flags(MEM_READ_WRITE)
    .len(INPUT_SIZE)
    .copy_host_slice(x)
    .build()
    .expect("Failed to create input buffer");

let weights_buffer = Buffer::<f32>::builder()
    .queue(self.queue.clone())
    .flags(MEM_READ_WRITE)
    .len(INPUT_SIZE)
    .copy_host_slice(&self.w_input_hidden)
    .build()
    .expect("Failed to create weights buffer");

let hidden_input_buffer = Buffer::<f32>::builder()
    .queue(self.queue.clone())
    .flags(MEM_READ_WRITE)
    .len(1) // Single hidden input value
    .build()
    .expect("Failed to create hidden input buffer");

// Set kernel arguments
self.forward_kernel
    .set_arg(0, &x_buffer)
    .expect("Failed to set input buffer");
self.forward_kernel
    .set_arg(1, &weights_buffer)
    .expect("Failed to set weights buffer");
self.forward_kernel
    .set_arg(2, &hidden_input_buffer)
    .expect("Failed to set hidden input buffer");
self.forward_kernel
    .set_arg(3, self.bias_hidden)
    .expect("Failed to set bias_hidden");

// Execute kernel
unsafe {
    self.forward_kernel.enq().expect("Failed to enqueue forward kernel");
}

// Read hidden input
let mut hidden_input = vec![0.0; 1];
hidden_input_buffer
    .read(&mut hidden_input)
    .enq()
    .expect("Failed to read hidden input");

let hidden_input = hidden_input[0];
let hidden_output = self.sigmoid(hidden_input);

```

```

        let final_input = hidden_output * self.w_hidden_output + self.bias_out-
put;

        let y_pred = self.sigmoid(final_input);

        (hidden_input, hidden_output, final_input, y_pred)
    }

    fn train(&mut self, X: &[Vec<f32>], Y: &[f32]) {
        for epoch in 0..EPOCHS {
            let mut total_error = 0.0;

            for (x, &y_true) in X.iter().zip(Y) {
                let (hidden_input, hidden_output, final_input, y_pred) =
self.forward_pass(x);

                let error = y_true - y_pred;
                total_error += error.powi(2);

                let d_y_pred = error * self.sigmoid_derivative(final_input);
                let d_hidden_output =
                    d_y_pred * self.w_hidden_output * self.sigmoid_deriva-
tive(hidden_input);

                // Update weights with OpenCL
                let x_buffer = Buffer::<f32>::builder()
                    .queue(self.queue.clone())
                    .flags(MEM_READ_WRITE)
                    .len(INPUT_SIZE)
                    .copy_host_slice(x)
                    .build()
                    .expect("Failed to create input buffer");

                let weights_buffer = Buffer::<f32>::builder()
                    .queue(self.queue.clone())
                    .flags(MEM_READ_WRITE)
                    .len(INPUT_SIZE)
                    .copy_host_slice(&self.w_input_hidden)
                    .build()
                    .expect("Failed to create weights buffer");

                self.backward_kernel
                    .set_arg(0, &x_buffer)
                    .expect("Failed to set input buffer");
                self.backward_kernel
                    .set_arg(1, &weights_buffer)
                    .expect("Failed to set weights buffer");
                self.backward_kernel
                    .set_arg(2, d_hidden_output)
                    .expect("Failed to set d_hidden_output");
                self.backward_kernel
                    .set_arg(3, LEARNING_RATE)

```

```

        .expect("Failed to set learning_rate");

        unsafe {
            self.backward_kernel
                .enq()
                .expect("Failed to enqueue backward kernel");
        }

        // Read updated weights
        weights_buffer
            .read(&mut self.w_input_hidden)
            .enq()
            .expect("Failed to read updated weights");

        // Update remaining weights and biases
        self.w_hidden_output += LEARNING_RATE * hidden_output * d_y_pred;
        self.bias_hidden += LEARNING_RATE * d_hidden_output;
        self.bias_output += LEARNING_RATE * d_y_pred;
    }

    if epoch % 100 == 0 {
        println!("Epoch {}: error = {:.4}", epoch, total_error);
    }
}

fn predict(&self, x: &[f32]) -> f32 {
    let (_, _, _, y_pred) = self.forward_pass(x);
    y_pred
}
}

pub fn test2() {
    let X = vec![
        vec![0.1, 0.2, 0.3, 0.4, 0.5],
        vec![0.2, 0.1, 0.4, 0.3, 0.5],
        vec![0.6, 0.7, 0.8, 0.9, 1.0],
        vec![0.9, 0.8, 1.0, 0.7, 0.6],
    ];

    let Y = vec![0.0, 0.0, 1.0, 1.0];

    let mut nn = NeuralNetwork::new();
    nn.train(&X, &Y);

    println!("\n=== Predictions on training data ===");
    for x in &X {
        let y_pred = nn.predict(x);
        println!("x = {:?} → y_pred = {:.4}", x, y_pred);
    }
}

```



```

let x_new = vec![0.5, 0.5, 0.5, 0.5, 0.5];
let y_pred_new = nn.predict(&x_new);
println!("\n=== Prediction on new input ===");
println!("x_new = {:?} → y_pred = {:.4}", x_new, y_pred_new);
}

```

kernels.cl

```

__kernel void forward_pass(
    __global const float *input,
    __global const float *weights,
    __global float *hidden_input,
    float bias_hidden
) {
    int gid = get_global_id(0);
    if (gid != 0) return; // Process only one work item

    float sum = 0.0f;
    for (int i = 0; i < 5; i++) { // INPUT_SIZE = 5
        sum += input[i] * weights[i];
    }
    hidden_input[0] = sum + bias_hidden;
}

__kernel void backward_pass(
    __global const float *input,
    __global float *weights,
    float d_hidden_output,
    float learning_rate
) {
    int gid = get_global_id(0);
    if (gid != 0) return; // Process only one work item

    for (int i = 0; i < 5; i++) { // INPUT_SIZE = 5
        weights[i] += learning_rate * input[i] * d_hidden_output;
    }
}


```

Протоколы, логи, скриншоты, графики.

```
Epoch 99300: total_error=0.0003
Epoch 99400: total_error=0.0003
Epoch 99500: total_error=0.0003
Epoch 99600: total_error=0.0003
Epoch 99700: total_error=0.0003
Epoch 99800: total_error=0.0003
Epoch 99900: total_error=0.0003
Epoch 100000: total_error=0.0003

=== PREDICTIONS ON TRAINING DATA ===
x=[0.1, 0.2, 0.3, 0.4, 0.5] → y_pred=0.0074
x=[0.2, 0.1, 0.4, 0.3, 0.5] → y_pred=0.0075
x=[0.6, 0.7, 0.8, 0.9, 1.0] → y_pred=0.9898
x=[0.9, 0.8, 1.0, 0.7, 0.6] → y_pred=0.9924

=== PREDICTION ON NEW INPUT ===
x_new=[0.5, 0.5, 0.5, 0.5, 0.5] → y_pred=0.7373
```



Замеры.

Программа на python при 100_000 эпох выдала результат 2.33с. Результат на rust превышал несколько минут, хотя предполагалось обратное.

Видеокарта – встроенная AMD – определённо не лучший вариант для вычислительных операций. Если посмотреть на диспетчер задач, то во время выполнения программы видеокарта была включена в работу. Существенное замедление происходило также из-за использования отдельного языка для описания работы с OpenCL.

Выводы

В ходе лабораторной работы были изучены основы параллельного программирования с использованием OpenCL, реализованы вычислительные задачи с применением графического ускорителя (GPU), оценена производительность и масштабируемость решений при выполнении вычислений.

Добиться ускорения за счёт GPU не удалось. Описание функций kernel имеет единую структуру, что позволяет писать независимый от аппаратной части код – это положительно влияет на масштабируемость.